
PORTAFOLIO DE CIENCIA DE DATOS

Predicción de Series Temporales • Python + Machine Learning

Modelo Random Forest Regressor para Predicción de Demanda de Viajes

*Minimización de Varianza • Agregación Bootstrap •
Optimización de Hiperparámetros*

Área: Movilidad Urbana • Optimización de Flota

Herramientas: Python 3 • scikit-learn • pandas

Modelo: Random Forest Regressor

Datos: TLC New York City Taxi Trip Duration

Índice

1	Introducción al Proyecto	3
2	Marco Teórico	4
2.1	Formalización de los Árboles de Regresión	4
2.2	Criterio de División (Minimización de Varianza)	4
2.3	Ensamblaje Bootstrap Aggregating (Random Forest)	4
2.4	Métricas de Evaluación Continua	5
3	Ingeniería de Datos y Diseño de Variables	6
3.1	Tratamiento de Valores Atípicos (Outliers)	6
4	Pipeline Computacional	7
4.1	Optimización de Hiperparámetros	7
5	Evaluación y Conclusiones del Negocio	8
5.1	Interpretación Analítica	8
5.2	Siguientes Pasos Metodológicos	8
6	Referencias	9

1. Introducción al Proyecto

Este proyecto implementa una canalización (pipeline) de Machine Learning para pronosticar la demanda horaria de viajes de transporte privado en la ciudad de Nueva York. El objetivo algorítmico es estimar el volumen total de transacciones (Y) en un bloque temporal específico, utilizando únicamente características derivadas de la estacionalidad (hora, día de la semana, mes).

La arquitectura seleccionada es el **Random Forest Regressor**, un meta-estimador de aprendizaje supervisado que ensambla múltiples árboles de decisión. Esta metodología resulta superior a la regresión lineal clásica para este dominio, dado que captura de forma no paramétrica y sin transformaciones polinomiales las relaciones altamente no lineales y cíclicas que rigen los procesos estacionales.

2. Marco Teórico

2.1 Formalización de los Árboles de Regresión

Un árbol de regresión particiona el espacio de las variables predictoras en regiones rectangulares mutuamente excluyentes. Sea un conjunto de entrenamiento compuesto por n observaciones (x_i, y_i) , donde $x_i \in \mathbb{R}^p$ es el vector de características y $y_i \in \mathbb{R}$ es la variable dependiente continua.

El objetivo del algoritmo es dividir el espacio en J regiones distintas $R_1, R_2, \dots, R_J$. Para cualquier observación que recaiga en la región R_j , la predicción del modelo $\hat{y}$ es una constante c_j . Funcionalmente, el modelo se expresa como:

$$f(x) = \sum_{j=1}^J c_j I(x \in R_j)$$

donde $I(\cdot)$ es la función indicadora y c_j es el promedio aritmético de las observaciones empíricas en dicha región.

2.2 Criterio de División (Minimización de Varianza)

Para construir el árbol, se emplea una partición binaria recursiva. En cada nodo, el algoritmo busca la variable j y el punto de corte s que minimizan la suma de los errores al cuadrado (SSE), lo cual es equivalente a minimizar la varianza interna de los nodos hijos resultantes.

Definiendo los semiplanos:

$$\begin{aligned} R_1(j, s) &= \{x \mid x_j \leq s\} \\ R_2(j, s) &= \{x \mid x_j > s\} \end{aligned}$$

El algoritmo resuelve el siguiente problema de optimización matricial:

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right]$$

Los valores óptimos $\hat{c}_1$ y $\hat{c}_2$ son siempre las medias condicionales de cada partición.

2.3 Ensamblaje Bootstrap Aggregating (Random Forest)

Un árbol individual profundo posee bajo sesgo pero es propenso al sobreajuste (alta varianza). El meta-estimador **Random Forest** mitiga este efecto promediando múltiples

árboles descorrelacionados.

Para construir un bosque de B árboles:

1. Se extraen B muestras con reemplazo (bootstrap) de los datos originales.
2. Se ajusta un árbol $\hat{f}_b(x)$ a cada muestra. Durante la división nodal, sólo se evalúa un subconjunto aleatorio $m \approx p/3$ de los predictores.
3. La predicción final se computa como la esperanza empírica del ensamble:

$$\hat{f}_{rf}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(x)$$

2.4 Métricas de Evaluación Continua

La bondad de ajuste y magnitud de error del modelo se evalúan empleando estadísticos de desviación sobre el conjunto de validación (out-of-sample).

Métrica	Fórmula Matemática	Interpretación Analítica
MAE	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Error promedio absoluto. Ponderación lineal de residuos.
RMSE	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	Desviación estándar de residuos. Penaliza errores grandes cuadráticamente.
R^2	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Proporción de varianza de la demanda explicada por la matriz estacional.

3. Ingeniería de Datos y Diseño de Variables

El conjunto de datos primario consiste en registros transaccionales de viajes. Para transformarlos en una serie de tiempo modelable, se aplicó una agregación temporal.

Variable	Tipo / Rango	Función Analítica
pickup_hour	datetime64	Marca de truncamiento horario (<i>floor</i> temporal).
hour	Numérico [0, 23]	Variable predictora. Modela ciclos intra-diarios.
day_of_week	Numérico [0, 6]	Variable predictora. Modela régimen laboral vs. fin de semana.
month	Numérico [1, 12]	Variable predictora. Modela estacionalidad macro (clima/vacaciones).
trip_count	Entero $\mathbb{Z}^+$	Variable objetivo. Volumen agregado de demanda.

3.1 Tratamiento de Valores Atípicos (Outliers)

Para preservar la integridad del gradiente durante la minimización de la varianza, se aislaron valores anómalos mediante el límite del Rango Inter cuartilico (IQR). Aquellos bloques horarios cuya demanda excede o disminuye el patrón normal en $1.5 \times \text{IQR}$ fueron purgados de la matriz de entrenamiento.

4. Pipeline Computacional

4.1 Optimización de Hiperparámetros

Dado que la estructura del árbol es paramétrica, se empleó una búsqueda en cuadrícula exhaustiva ([GridSearchCV](#)) para determinar la configuración topológica óptima.

```
from sklearn.model_selection import GridSearchCV from sklearn.ensemble
import RandomForestRegressor

# Definicion del subespacio de hiperparametros
param_grid = {
    'n_estimators': [50, 100, 200], # Numero B de arboles
    'max_depth': [None, 10, 20, 30], # Profundidad maxima
    'min_samples_split': [2, 5, 10] # Obs. para dividir nodo
}

# Instancia del meta-estimador base
rf_base = RandomForestRegressor(random_state=42)

# Optimizacion via validacion cruzada (3-fold)
grid_search = GridSearchCV(
    estimator=rf_base,
    param_grid=param_grid,
    cv=3,
    scoring='neg_mean_squared_error',
    n_jobs=-1
)

grid_search.fit(X_train, y_train)
```

Nota Computacional: El scoring `neg_mean_squared_error` es un artificio de Scikit-Learn; dado que las rutinas de optimización están diseñadas para maximizar métricas, el MSE es devuelto en su formato negativo.

5. Evaluación y Conclusiones del Negocio

Tras la evaluación empírica del algoritmo de ensamblaje sobre la matriz de prueba estricta (hold-out test set), las métricas de precisión arrojaron los siguientes estadísticos definitivos:

Resultados de Validación Out-of-Sample:

- **MAE:** 14.79 viajes por hora
- **RMSE:** 21.32 viajes por hora
- **R^2 :** 0.8953 (89.53 % de la varianza explicada)

5.1 Interpretación Analítica

1. **Alta Capacidad Estructural (R^2):** El coeficiente de determinación revela que casi el 90 % del comportamiento de la demanda en NYC puede mapearse de forma determinista únicamente conociendo la ubicación temporal (hora/día/mes). Las particiones del árbol capturaron eficazmente esta dependencia cíclica.
2. **Viabilidad Operativa (MAE):** El error absoluto medio de ≈ 15 viajes representa una desviación mínima frente a las miles de transacciones procesadas por hora. El modelo es operativamente viable para integrarse en un sistema de enrutamiento predictivo (*predictive dispatching*), ubicando flotas antes de que surja la demanda real.
3. **Asimetría de Error (Brecha RMSE-MAE):** El hecho de que el RMSE (21.32) exceda al MAE (14.79) indica la presencia de asimetría residual. Matemáticamente, las predicciones sufren de errores de magnitud atípica en horas específicas. Desde la óptica del negocio, estas desviaciones representan **eventos exógenos** no modelados en la matriz actual, tales como anomalías meteorológicas (precipitaciones) o disrupciones imprevistas en el transporte público.

5.2 Siguiendo Pasos Metodológicos

Para mitigar la varianza residual evidenciada por el RMSE, la próxima iteración del modelo requerirá la integración de covariables externas; específicamente, se propone ejecutar *joins* relacionales (vía SQL) con métricas climáticas horarias y matrices booleanas de días festivos nacionales.

6. Referencias

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Taxi and Limousine Commission (TLC) of New York City. (2023). *TLC Trip Record Data*. Recuperado del repositorio oficial de datos abiertos gubernamentales.